

Ziak est-il un autre rappeur ?

Une enquête stylométrique sur le corpus LRFAF du rap français

Tassilo Westphalen

CPES Sciences des données, Arts et Cultures — Université PSL / Lycée Louis-le-Grand

Résumé. Le rappeur Ziak est apparu en 2020 masqué et sans identité publique, ce qui a nourri l'hypothèse d'un artiste déjà établi rattaché sous un pseudonyme. Cette hypothèse est testable : si Ziak est le second nom d'un rappeur du corpus, ses textes doivent porter la même signature statistique. Nous conduisons ce test sur LRFAF (37 307 chansons de rap français) au moyen d'un protocole d'attribution d'auteur à taille contrôlée, validé sur 177 artistes dont la réponse est connue. Deux résultats. D'une part, méthodologique : l'approche intuitive, qui compare des corpus d'artistes entiers, produit un classement d'apparence convaincante mais n'identifie le bon auteur que dans 25 % des cas — elle se trompe trois fois sur quatre, car elle mesure surtout la quantité de texte disponible. D'autre part, empirique : avec un protocole dont on établit qu'il retrouve le bon auteur dans 90 % des cas, aucun des 392 artistes éligibles ne présente la signature de Ziak. Le nom le plus avancé par les auditeurs, Mikeyssem, absent du corpus, a été collecté et testé séparément : il ne correspond pas davantage. Ziak écrit au centre de son genre, sans excentricité mesurable, mais sans proche parent identifiable.

Mots-clés : stylométrie, attribution d'auteur, rap français, Delta de Burrows, méthode des imposteurs, LRFAF.

1. Introduction

Ziak publie son premier titre en 2020. Cagoulé en public, il ne divulgue aucune identité civile et cultive ouvertement le mystère. Cette discrétion a nourri parmi les auditeurs une hypothèse récurrente : le nom masquerait un artiste déjà établi, qui aurait recommencé une carrière sous un pseudonyme.

Cette hypothèse a la particularité d'être *testable*. La stylométrie repose sur un constat empirique ancien : les habitudes d'écriture les moins conscientes d'un auteur — fréquence des mots grammaticaux, enchaînements de caractères, élisions — forment une signature relativement stable, que le changement de nom n'efface pas. Si Ziak est le second nom d'un rappeur présent dans le corpus, ses textes doivent porter la même signature que ceux de cet artiste.

L'enjeu principal de ce travail n'est pas l'algorithme mais le **protocole**. Une question d'attribution ne se règle pas en calculant des distances : elle se règle en sachant ce que ces distances valent. Nous montrons en section 3 qu'une démarche intuitive, appliquée aux mêmes données, désigne un artiste avec assurance et se trompe trois fois sur quatre. La contribution de cet article tient donc autant à la manière de poser la question qu'à la réponse obtenue.

2. Données

2.1 Le corpus LRFAF

Le corpus LRFAF (de Courson, 2024) rassemble 37 307 textes de rap français issus de genius.com, obtenus en croisant les catégories Wikipédia et Wikidata avec l'API de Genius, puis en extrayant les paroles au moyen du paquet *lyricsgenius*. Il fournit, outre les textes, des métadonnées (artiste, année, vues, contributeurs) et une batterie de mesures lexicométriques.

Après nettoyage — suppression des textes de moins de 100 mots et des doublons de paroles entre artistes, qui correspondent à des featurings ou à des rééditions — l'analyse porte sur 32 923 titres et 596 artistes.

2.2 Le corpus de Ziak

Ziak y est représenté par 43 titres publiés entre 2020 et 2024, soit 23 886 mots. C'est un volume modeste mais très au-dessus du seuil usuel de quelques milliers de mots requis par les méthodes employées ici. La section 5.1 vérifiera empiriquement que cette matière suffit.

Un point de vocabulaire commande tout le reste. Nous cherchons une **vérification d'auteur en ensemble ouvert** : la bonne réponse peut ne pas figurer dans le corpus. C'est une tâche plus difficile que l'attribution en ensemble fermé, où l'on sait que l'auteur est l'un des candidats — une méthode d'ensemble fermé désigne *toujours* quelqu'un. Il faut donc un protocole capable de répondre « personne ».

3. Pourquoi la démarche intuitive désigne le mauvais artiste

La démarche spontanée consiste à concaténer toutes les chansons de chaque artiste, à vectoriser, puis à classer les candidats par distance à Ziak. Elle produit un palmarès plausible. Le problème apparaît lorsqu'on le confronte à une variable qui n'a rien à voir avec le style : la simple quantité de texte disponible sur chaque artiste.

La corrélation de Spearman entre la distance à Ziak et la taille du corpus du candidat atteint $-0,47$: près d'un quart de la variance du classement tient à cette seule quantité. Le mécanisme est arithmétique, non musical : plus un artiste a écrit, plus son vecteur couvre de n-grammes, et plus il ressemble à n'importe quel texte. Les vingt « plus proches » de Ziak ont un corpus deux fois plus gros que la médiane.

L'argument décisif n'est pas qu'un classement change, mais qu'on peut mesurer lequel a raison. Nous soumettons trois variantes au même protocole de vérité-terrain : on prélève chez un artiste un échantillon de la taille du corpus de Ziak, on le traite comme un texte anonyme, et l'on regarde si la méthode le rattache au reste de son œuvre.

Tableau 1. Puissance des trois variantes, évaluée sur 177 artistes dont la réponse est connue. Le contrôle de la taille des documents apporte 48 points, la standardisation des traits 18 de plus.

Variante	Rang 1	Top 5	Top 20	Rang médian
A. naïve (corpus complets)	25,0 %	45,5 %	67,4 %	7
B. taille contrôlée	73,5 %	87,4 %	95,1 %	1
C. taille contrôlée + Cosine Delta	91,5 %	97,7 %	99,8 %	1

L'approche naïve identifie le bon auteur dans un quart des cas seulement, alors qu'elle produit un classement d'allure sérieuse. Ramener tous les documents à une taille identique porte ce taux à 74 %, et standardiser les traits à 92 %. Sans étalonnage, un classement de distances ne permet aucune conclusion, quelle que soit sa netteté apparente.




Figure 1. Ce que mesure l'approche naïve. (a) la distance à Ziak décroît avec la taille du corpus du candidat ; (b) les rangs se réorganisent entièrement une fois la taille neutralisée — Mister You passe du 9^e au 138^e rang ; (c) puissance comparée sur vérité-terrain.

4. Protocole

Le protocole retenu repose sur trois choix. **Les traits** sont les 4-grammes de caractères et les 500 mots les plus fréquents : des descripteurs qui captent des habitudes d'écriture largement inconscientes plutôt que les thèmes abordés. **Les distances** sont le Cosine Delta (Smith & Aldridge, 2011) et le Delta de Burrows (1992), calculées sur des traits standardisés. **La taille** est contrôlée : chaque candidat est représenté par 12 000 mots exactement, échantillonnés parmi ses titres.

Chaque artiste de contrôle est traité *exactement* comme Ziak : on lui prélève un texte-requête de la taille du corpus de Ziak, et un « jumeau » de 12 000 mots issu de titres disjoints, placé dans le pool. Deux conditions sont évaluées : H_1 , où le jumeau est présent, qui mesure la puissance ; et H_0 , où il est retiré, qui reproduit la situation d'un auteur absent du corpus — c'est-à-dire l'hypothèse à laquelle Ziak devra être confronté.

Tableau 2. Puissance des quatre combinaisons, sur 1 770 essais couvrant 177 artistes. Les 4-grammes de caractères associés au Cosine Delta dominant.

Traits	Distance	Rang 1	Top 5	Top 20
char	cosine delta	90,0 %	98,5 %	99,7 %
mfw	cosine delta	85,0 %	96,6 %	99,4 %
mfw	burrows delta	79,1 %	92,0 %	97,6 %
char	burrows delta	65,3 %	85,6 %	95,2 %

La meilleure combinaison retrouve le bon auteur au premier rang dans 90 % des cas et dans le top 5 dans 98,5 %. C'est cette puissance élevée qui rendra un résultat négatif informatif : si un alias existait dans le corpus, la méthode aurait neuf chances sur dix de le désigner en tête.

La distance brute au meilleur candidat ne se lit pas seule. Nous lui substituons un **score de séparation** : de combien d'écart-types le meilleur candidat se détache-t-il des autres ? Cette grandeur est comparable d'une requête à l'autre. Un auteur réellement présent produit une séparation moyenne de -4,59 ; un auteur absent, de -3,05. L'écart entre ces deux distributions fournit le critère de décision.




Figure 2. Validation du protocole. (a) courbe de rappel de la meilleure combinaison ; (b) les quatre combinaisons testées ; (c) puissance par génération d'artistes — elle est maximale sur celle de Ziak.

5. Résultats

5.1 Le style de Ziak est-il détectable ?

Avant d'interpréter un échec d'identification, il faut écarter l'explication triviale : un corpus trop petit ou trop hétérogène pour porter une signature. Nous coupons donc le corpus de Ziak en deux moitiés disjointes et cherchons la seconde depuis la première. **La moitié cible ressort au premier rang dans 100 % des tirages** avec la meilleure combinaison, parmi 392 candidats. Le style de Ziak est donc parfaitement détectable et son corpus suffisamment homogène : aucun échec ultérieur ne pourra être imputé à une insuffisance de matière.

5.2 Aucun candidat ne s'impose

Nous classons ensuite les 392 autres artistes, sur 30 rééchantillonnages et avec les quatre combinaisons. Le résultat est éloquent par son incohérence : chaque méthode a son favori — Beendo Z, Rimkus, Zkr, L'Animalerie — et **aucun candidat ne s'impose d'une méthode à l'autre**. Pour les artistes de contrôle, dont la réponse est connue, les quatre combinaisons convergent dans neuf cas sur dix. Ici, elles divergent.

5.3 Verdict

Tableau 3. Confrontation aux deux hypothèses. Les quatre analyses concordent : la séparation observée pour Ziak est non seulement très loin de ce que produit un alias authentique, mais se situe dans la queue de la distribution des auteurs absents.

Traits	Distance	Séparation de Ziak	Repère H_1 (auteur présent)	Repère H_0 (auteur absent)	Hypothèse favorisée
char	burrows delta	-2,13	-3,01	-2,33	H_0
char	cosine delta	-2,52	-4,59	-3,05	H_0
mfw	burrows delta	-2,22	-3,27	-2,40	H_0
mfw	cosine delta	-2,83	-4,83	-3,26	H_0

Autrement dit, ce n'est pas seulement que la méthode ne trouve pas : c'est qu'elle trouve activement l'absence de correspondance.




Figure 3. Ziak confronté aux deux hypothèses, pour les quatre combinaisons. La distribution verte correspond aux cas où l'auteur est réellement dans le corpus, la grise aux cas où il en est absent ; le trait rouge marque la position de Ziak.

5.4 Robustesse

Trois objections méritent une réponse chiffrée. **La méthode est-elle moins puissante sur les artistes récents ?** C'est l'inverse : la puissance est maximale sur la génération de Ziak (97,7 % au premier rang pour 2021-2024). **Le seuil de 12 000 mots exclut-il le bon candidat ?** Le score de séparation reste compris entre -2,43 et -2,58 lorsqu'on fait varier ce seuil de 5 000 à 25 000 mots, faisant varier le pool de 472 à 268 artistes. **Les candidats récurrents résistent-ils à un test par paire ?**

Le test des imposteurs (Koppel & Winter, 2014) ne demande plus « qui est le plus proche ? » mais « ce candidat précis l'emporte-t-il sur un fond d'imposteurs tirés au hasard ? ». Il appelle une lecture en deux temps. D'un côté, les meilleurs candidats — Kerchak (0,82), Beendo Z (0,72), Rimkus (0,70) — battent largement le hasard (0,04) : il existe une parenté stylistique réelle. De l'autre, un alias authentique obtient dans ce test un score médian de 1,00, et neuf vrais jumeaux sur dix dépassent 0,97. Le meilleur candidat de Ziak reste sous le niveau de 97,5 % des jumeaux authentiques.

Cette distinction — ressembler à un courant *versus* être la même personne — est précisément ce qu'un classement de distances non étalonné ne permet jamais de trancher.




Figure 4. (a) aucun candidat n'est stable d'une méthode à l'autre ; (b) même le meilleur candidat reste loin du niveau qu'atteint un véritable alias.

6. Le cas Mikeysem

La conclusion précédente souffrait d'un angle mort : le nom le plus fréquemment avancé par les auditeurs, **Mikeysem**, ne figure pas dans LRFAF. Ce n'est pas un oubli du corpus mais une conséquence de son critère d'inclusion, qui part des catégories Wikipédia : Mikeysem n'a ni article Wikipédia ni entrée Wikidata. L'hypothèse la plus discutée était donc précisément celle que l'étude ne pouvait pas tester.

Ses titres ont été collectés sur Genius et passés dans le pipeline LRFAF reconstitué. **La couverture est partielle et c'est la principale faiblesse de cette section** : sa discographie compte 21 titres mais 7 seulement disposent d'une page Genius soit 3 745 mots — trois fois moins que la taille de référence employée jusqu'ici. Les autres n'ont aucune transcription disponible, dont l'intégralité du projet *Prochains Héritiers* (10 titres, 2022). Aller chercher ces paroles ailleurs romprait la compatibilité méthodologique avec LRFAF, dont toutes les transcriptions proviennent de Genius et de ses conventions.

Cette petitesse impose de recalibrer avant d'interpréter. À 3 745 mots de candidat, la méthode place le vrai auteur au premier rang dans 63 % des cas et dans le top 20 dans 95 % : la puissance baisse, mais un alias authentique resterait très majoritairement détectable.

Tableau 4. Rangs médians vus depuis Ziak, à taille strictement égale. Six artistes que personne ne soupçonne sont plus proches de Ziak que Mikeysem.

Artiste	Rang parmi 493 candidats
Kerchak	4
Beendo Z	8
ISK	10
Werenoï	12
Zkr	18
Rimkus	25
Mikeysem	64

Aucune des quatre combinaisons ne place Mikeysem dans le top 20 : son rang médian est de 58 sur 493. Son score de séparation (-1,22) est même plus faible que celui d'un auteur typiquement absent du corpus : il n'est pas un candidat ordinaire ayant manqué la première place, mais un artiste particulièrement éloigné. Au test des imposteurs, il obtient 0,07, à peine au-dessus du hasard (0,04), là où un alias authentique atteint 0,83 en médiane ; seuls 5 % des vrais jumeaux font moins bien.

Ziak et Mikeysem ne se ressemblent pas plus que des voisins de genre




Figure 5. Test de l'hypothèse Mikeysem. (a) puissance de la méthode à cette taille de corpus ; (b) rangs comparés ; (c) le score obtenu reste très en deçà de celui d'un véritable alias.

Une réserve doit accompagner ce résultat. Un contrôle d'auto-cohérence — une moitié du corpus de Mikeysem cherchant l'autre, avec environ 1 870 mots de chaque côté — échoue complètement. Ce test est plus exigeant que le test principal, qui dispose des 23 886 mots de Ziak comme requête, et ne remet donc pas en cause le classement ; mais il rappelle, avec la couverture partielle signalée plus haut, que la conclusion de cette section vaut comme faisceau convergent et non comme démonstration.

7. Portrait stylométrique de Ziak

À défaut d'identifier Ziak, on peut le caractériser. Deux mesures doivent être distinguées : la distance médiane à l'ensemble du corpus, qui dit s'il est atypique ; et la distance à son plus proche voisin, qui dit s'il a un parent.

Ziak n'a rien d'un excentrique : il se situe au rang 176 sur 393, au milieu exact du genre, très loin des vrais atypiques du corpus que sont Manau, Grand Corps Malade ou Rocé. Et pourtant **il n'a pas de proche parent** : 68 % des artistes ont un voisin plus proche que le sien. C'est exactement la signature attendue d'un auteur qui écrit dans les codes d'un courant sans qu'aucun artiste du corpus ne soit sa seconde identité.

Ses marqueurs les plus robustes sont des **onomatopées** : « uh » (×149), « huh » (×87), « pow » (×64), les ad-libs qui ponctuent ses morceaux, suivis d'un argot situé (« zipette », « sheitan »).

Une mise en garde s'impose toutefois sur ces marqueurs. Le trait le plus spectaculaire de son corpus, à première vue, est un sous-emploi massif de « je » — cinq fois moins que la moyenne. C'est un artefact : il emploie « j' » 1,2 fois plus, et une fois les deux formes additionnées l'écart disparaît complètement (×0,99). La moitié des paires testées relève du même phénomène. Ce que l'on mesurait n'était pas une habitude d'écriture mais une convention de transcription : les paroles de Genius sont saisies par des contributeurs bénévoles, et « j'suis » ou « je suis » notent la même diction.

Enfin, l'écart entre ses deux périodes de production (2020-2021 et 2022-2024) dépasse à peine ce que produit une coupe aléatoire de son œuvre ($z = +1,71$, sous le seuil usuel de 2) : son style évolue un peu, sans rupture.

Portrait stylométrique de Ziak




Figure 6. Portrait stylométrique. (a) marqueurs lexicaux ; (b) Ziak n'a pas de proche parent ; (c) l'élision, un faux marqueur qui vient du transcripateur et non de l'auteur.

8. Limites

Le corpus n'est pas le rap français. LRFAF couvre 596 artistes, et l'analyse n'en retient que 393 — ceux disposant d'au moins 12 000 mots. Un artiste peu documenté, ou absent de Genius, ne pouvait pas être détecté. La section 6 lève ce point pour le seul candidat qui comptait vraiment, mais il en reste d'autres, hors corpus et non testés.

Les featurings ne sont pas séparés. Les paroles du corpus ne comportent aucune balise de section : le couplet d'un invité est attribué à l'artiste principal. Ce bruit affecte Ziak comme les candidats, et tend à rapprocher artificiellement les artistes qui collaborent — donc à faciliter une détection, non à l'empêcher.

Les transcriptions sont médiées. Comme le montre le cas de l'élosion, une partie du signal apparent vient des contributeurs de Genius plutôt que des artistes. Les 4-grammes de caractères y sont moins sensibles que les mots, sans y être immunisés.

Le corpus de Mikeysem est mince et partiel : 3 745 mots, couvrant 7 de ses 21 titres. C'est la conclusion la moins solidement étayée de ce travail.

Un alias n'écrit pas forcément comme lui-même. Un artiste changeant délibérément d'identité peut changer de registre. Notre validation mesure la puissance sur des jumeaux « faciles » — deux moitiés d'une même œuvre — et fournit donc une borne *optimiste*. Cette limite est la plus sérieuse, et elle joue dans un seul sens : elle affaiblit la conclusion « Ziak n'est personne du corpus » sans jamais soutenir une identification particulière.

9. Conclusion

L'hypothèse du pseudonyme était testable, et le test est concluant : aucun des 392 autres artistes éligibles du corpus LRFAF ne présente la signature stylométrique de Ziak, alors qu'un protocole validé sur 177 cas connus retrouve le bon auteur neuf fois sur dix — et dans 97,7 % des cas pour sa génération. Les quatre analyses convergent vers l'hypothèse d'un auteur absent du corpus, et le test par paire montre que même le meilleur candidat reste en deçà de 97,5 % des alias authentiques. Le nom que la rumeur avance le plus souvent, testé à son tour, se classe 58^e sur 493, derrière six artistes que personne ne soupçonne.

Ce que l'on observe à la place a sa propre valeur descriptive : Ziak écrit au centre de son genre, sans excentricité mesurable, mais sans proche parent non plus. Sa parenté avec Kerchak ou Beendo Z est celle d'une génération et d'un sous-genre partagés, pas d'une main commune.

La contribution la plus transposable de ce travail est cependant méthodologique. Une même question, posée au même corpus, reçoit deux réponses opposées selon le protocole : l'approche intuitive désigne un artiste avec assurance et se trompe trois fois sur quatre ; l'approche étalonnée ne désigne personne, et sait dire pourquoi. Entre les deux, il n'y a pas un algorithme plus sophistiqué, mais trois exigences ordinaires — contrôler une variable de confusion, valider sur des cas connus, calibrer contre une hypothèse nulle.

Note éthique

Cette étude porte sur une personne réelle ayant fait le choix de l'anonymat. Deux précautions ont guidé le travail. Elle s'appuie exclusivement sur des données publiques de recherche et sur des textes publiés, sans recours à aucune information personnelle. Surtout, la stylométrie n'établit pas d'identité civile : une correspondance forte aurait constitué un indice de parenté textuelle, jamais une preuve — et elle aurait appelé, à ce titre, une retenue plus grande encore dans sa publication que le résultat négatif obtenu ici. Le rapprochement avec Mikeysem, en particulier, est une spéculation d'auditeurs que l'intéressé a démentie et qu'aucune source vérifiable n'étaye. Le résultat de cette enquête est, à sa manière, une confirmation de la robustesse de cet anonymat face aux méthodes quantitatives.

Reproductibilité

L'ensemble des analyses est reproductible depuis le dépôt du projet. Les scripts s'exécutent dans l'ordre : construction du cache de compteurs, diagnostic du biais de taille, validation du protocole, application à Ziak, robustesse, portrait, collecte de Mikeysem, test de l'hypothèse, figures. Le corpus LRFAF n'étant pas versionné (114 Mo), il est retéléchargé depuis Hugging Face. Le pipeline LRFAF reconstitué et son rapport de reproductibilité — qui documente colonne par colonne ce qui est reproduit exactement, approximé ou impossible à

retrouver — accompagnent le dépôt.

Références

- Burrows, J. (2002). Delta : a measure of stylistic difference and a guide to likely authorship. *Literary and Linguistic Computing*, 17(3), 267-287.
- de Courson, B. (2024). *LRFAF : une exploration numérique du rap français depuis les années 1990*. Jeu de données : huggingface.co/datasets/regicid/LRFAF
- Evert, S., Proisl, T., Jannidis, F. *et al.* (2017). Understanding and explaining Delta measures for authorship attribution. *Digital Scholarship in the Humanities*, 32(suppl. 2), ii4-ii16.
- Koppel, M. & Winter, Y. (2014). Determining if two documents are written by the same author. *Journal of the Association for Information Science and Technology*, 65(1), 178-187.
- Monroe, B., Colaresi, M. & Quinn, K. (2008). Fightin' words : lexical feature selection and evaluation for identifying the content of political conflict. *Political Analysis*, 16(4), 372-403.
- Piolat, A., Booth, R. J., Chung, C. K., Davids, M. & Pennebaker, J. W. (2011). La version française du dictionnaire pour le LIWC. *Psychologie Française*, 56(3), 145-159.
- Smith, P. & Aldridge, W. (2011). Improving authorship attribution : optimizing Burrows' Delta method. *Journal of Quantitative Linguistics*, 18(1), 63-88.