

# Ziak est-il un autre rappeur ?

*Une enquête stylométrique sur le corpus LRFAF du rap français*

Tassilo Westphalen

CPES Sciences des données, Arts et Cultures — Université PSL / Lycée Louis-le-Grand

**Résumé.** Le rappeur Ziak est apparu en 2020 masqué et sans identité publique, ce qui a nourri l'hypothèse d'un artiste déjà établi rattaché sous un pseudonyme. Cette hypothèse est testable : si Ziak est le second nom d'un rappeur du corpus, ses textes doivent porter la même signature statistique. Nous conduisons ce test sur LRFAF (37 307 chansons de rap français) au moyen d'un protocole d'attribution d'auteur à taille contrôlée, validé sur 177 artistes dont la réponse est connue. Deux résultats. D'une part, méthodologique : l'approche intuitive, qui compare des corpus d'artistes entiers, produit un classement d'apparence convaincante mais n'identifie le bon auteur que dans 25 % des cas — elle se trompe trois fois sur quatre, car elle mesure surtout la quantité de texte disponible. D'autre part, empirique : avec un protocole dont on établit qu'il retrouve le bon auteur dans 90 % des cas, aucun des 392 artistes éligibles ne présente la signature de Ziak. Le nom le plus avancé par les auditeurs, Mikeyssem, absent du corpus, a été collecté et testé séparément : il ne correspond pas davantage. Une autre version de la rumeur, selon laquelle le rappeur web7 (ex-7 Jaws) écrirait ses textes, trouve un appui partiel : web7 est crédité co-auteur de 10 titres, et ceux qu'il co-signe sur l'album *Essonne History X* sont stylométriquement plus proches de son écriture ( $p = 0,04$ ), sans que rien n'indique qu'il écrive l'essentiel de l'œuvre. Ziak écrit au centre de son genre, sans excentricité mesurable, mais sans proche parent identifiable.

**Mots-clés :** stylométrie, attribution d'auteur, rap français, Delta de Burrows, méthode des imposteurs, ghostwriting, LRFAF.

## 1. Introduction

Ziak publie son premier titre en 2020. Cagoulé en public, il ne divulgue aucune identité civile et cultive ouvertement le mystère. Cette discrétion a nourri parmi les auditeurs une hypothèse récurrente : le nom masquerait un artiste déjà établi, qui aurait recommencé une carrière sous un pseudonyme. D'autres versions attribuent plutôt l'écriture de ses textes à un autre rappeur.

Cette hypothèse a la particularité d'être *testable*. La stylométrie repose sur un constat empirique ancien : les habitudes d'écriture les moins conscientes d'un auteur — fréquence des mots grammaticaux, enchaînements de caractères, élisions — forment une signature relativement stable, que le changement de nom n'efface pas. Si Ziak est le second nom d'un rappeur présent dans le corpus, ses textes doivent porter la même signature que ceux de cet artiste.

L'enjeu principal de ce travail n'est pas l'algorithme mais le **protocole**. Une question d'attribution ne se règle pas en calculant des distances : elle se règle en sachant ce que ces distances valent. Nous montrons en section 3 qu'une démarche intuitive, appliquée aux mêmes données, désigne un artiste avec assurance et se trompe trois fois sur quatre. La contribution de cet article tient donc autant à la manière de poser la question qu'à la réponse obtenue.

## 2. Données

### 2.1 Le corpus LRFAF

Le corpus LRFAF (de Courson, 2024) rassemble 37 307 textes de rap français issus de genius.com, obtenus en croisant les catégories Wikipédia et Wikidata avec l'API de Genius, puis en extrayant les paroles au moyen du paquet *lyricsgenius*. Il fournit, outre les textes, des métadonnées (artiste, année, vues, contributeurs) et une batterie de mesures lexicométriques.

Après nettoyage — suppression des textes de moins de 100 mots et des doublons de paroles entre artistes, qui correspondent à des featurings ou à des rééditions — l'analyse porte sur 32 923 titres et 596 artistes.

2.2 Le corpus de Ziak

Ziak y est représenté par 43 titres publiés entre 2020 et 2024, soit 23 886 mots. C'est un volume modeste mais très au-dessus du seuil usuel de quelques milliers de mots requis par les méthodes employées ici. La section 5.1 vérifiera empiriquement que cette matière suffit.

Un point de vocabulaire commande tout le reste. Nous cherchons une **vérification d'auteur en ensemble ouvert** : la bonne réponse peut ne pas figurer dans le corpus. C'est une tâche plus difficile que l'attribution en ensemble fermé, où l'on sait que l'auteur est l'un des candidats — une méthode d'ensemble fermé désigne *toujours* quelqu'un. Il faut donc un protocole capable de répondre « personne ».

3. Pourquoi la démarche intuitive désigne le mauvais artiste

La démarche spontanée consiste à concaténer toutes les chansons de chaque artiste, à vectoriser, puis à classer les candidats par distance à Ziak. Elle produit un palmarès plausible. Le problème apparaît lorsqu'on le confronte à une variable qui n'a rien à voir avec le style : la simple quantité de texte disponible sur chaque artiste.

La corrélation de Spearman entre la distance à Ziak et la taille du corpus du candidat atteint  $-0,47$  : près d'un quart de la variance du classement tient à cette seule quantité. Le mécanisme est arithmétique, non musical : plus un artiste a écrit, plus son vecteur couvre de n-grammes, et plus il ressemble à n'importe quel texte. Les vingt « plus proches » de Ziak ont un corpus deux fois plus gros que la médiane.

L'argument décisif n'est pas qu'un classement change, mais qu'on peut mesurer lequel a raison. Nous soumettons trois variantes au même protocole de vérité-terrain : on prélève chez un artiste un échantillon de la taille du corpus de Ziak, on le traite comme un texte anonyme, et l'on regarde si la méthode le rattache au reste de son œuvre.

Tableau 1. Puissance des trois variantes, évaluée sur 177 artistes dont la réponse est connue. Le contrôle de la taille des documents apporte 48 points, la standardisation des traits 18 de plus.

| Variante                           | Rang 1 | Top 5  | Top 20 | Rang médian |
|------------------------------------|--------|--------|--------|-------------|
| A. naïve (corpus complets)         | 25,0 % | 45,5 % | 67,4 % | 7           |
| B. taille contrôlée                | 73,5 % | 87,4 % | 95,1 % | 1           |
| C. taille contrôlée + Cosine Delta | 91,5 % | 97,7 % | 99,8 % | 1           |

L'approche naïve identifie le bon auteur dans un quart des cas seulement, alors qu'elle produit un classement d'allure sérieuse. Ramener tous les documents à une taille identique porte ce taux à 74 %, et standardiser les traits à 92 %. Sans étalonnage, un classement de distances ne permet aucune conclusion, quelle que soit sa netteté apparente.




Figure 1. Ce que mesure l'approche naïve. (a) la distance à Ziak décroît avec la taille du corpus du candidat ; (b) les rangs se réorganisent entièrement une fois la taille neutralisée — Mister You passe du 9<sup>e</sup> au 138<sup>e</sup> rang ; (c) puissance comparée sur vérité-terrain.

4. Protocole

Le protocole retenu repose sur trois choix. **Les traits** sont les 4-grammes de caractères et les 500 mots les plus fréquents : des descripteurs qui captent des habitudes d'écriture largement inconscientes plutôt que les thèmes abordés. **Les distances** sont le Cosine Delta (Smith & Aldridge, 2011) et le Delta de Burrows (1992), calculées sur des traits standardisés. **La taille** est contrôlée : chaque candidat est représenté par 12 000 mots exactement, échantillonnés parmi ses titres.


Chaque artiste de contrôle est traité *exactement* comme Ziak : on lui prélève un texte-requête de la taille du corpus de Ziak, et un « jumeau » de 12 000 mots issu de titres disjoints, placé dans le pool. Deux conditions sont évaluées :  $H_1$ , où le jumeau est présent, qui mesure la puissance ; et  $H_0$ , où il est retiré, qui reproduit la situation d'un auteur absent du corpus — c'est-à-dire l'hypothèse à laquelle Ziak devra être confronté.

**Tableau 2.** Puissance des quatre combinaisons, sur 1 770 essais couvrant 177 artistes. Les 4-grammes de caractères associés au Cosine Delta dominant.

| Traits | Distance      | Rang 1 | Top 5  | Top 20 |
|--------|---------------|--------|--------|--------|
| char   | cosine delta  | 90,0 % | 98,5 % | 99,7 % |
| mfw    | cosine delta  | 85,0 % | 96,6 % | 99,4 % |
| mfw    | burrows delta | 79,1 % | 92,0 % | 97,6 % |
| char   | burrows delta | 65,3 % | 85,6 % | 95,2 % |

La meilleure combinaison retrouve le bon auteur au premier rang dans 90 % des cas et dans le top 5 dans 98,5 %. C'est cette puissance élevée qui rendra un résultat négatif informatif : si un alias existait dans le corpus, la méthode aurait neuf chances sur dix de le désigner en tête.

La distance brute au meilleur candidat ne se lit pas seule. Nous lui substituons un **score de séparation** : de combien d'écart-types le meilleur candidat se détache-t-il des autres ? Cette grandeur est comparable d'une requête à l'autre. Un auteur réellement présent produit une séparation moyenne de  $-4,59$  ; un auteur absent, de  $-3,05$ . L'écart entre ces deux distributions fournit le critère de décision.



**Figure 2.** Validation du protocole. (a) courbe de rappel de la meilleure combinaison ; (b) les quatre combinaisons testées ; (c) puissance par génération d'artistes — elle est maximale sur celle de Ziak.

## 5. Résultats

### 5.1 Le style de Ziak est-il détectable ?

Avant d'interpréter un échec d'identification, il faut écarter l'explication triviale : un corpus trop petit ou trop hétérogène pour porter une signature. Nous coupons donc le corpus de Ziak en deux moitiés disjointes et cherchons la seconde depuis la première. **La moitié cible ressort au premier rang dans 100 % des tirages** avec la meilleure combinaison, parmi 392 candidats. Le style de Ziak est donc parfaitement détectable et son corpus suffisamment homogène : aucun échec ultérieur ne pourra être imputé à une insuffisance de matière.

### 5.2 Aucun candidat ne s'impose

Nous classons ensuite les 392 autres artistes, sur 30 rééchantillonnages et avec les quatre combinaisons. Le résultat est éloquent par son incohérence : chaque méthode a son favori — Beendo Z, Rimkus, Zkr, L'Animalerie — et **aucun candidat ne s'impose d'une méthode à l'autre**. Pour les artistes de contrôle, dont la réponse est connue, les quatre combinaisons convergent dans neuf cas sur dix. Ici, elles divergent.

5.3 Verdict

Tableau 3. Confrontation aux deux hypothèses. Les quatre analyses concordent : la séparation observée pour Ziak est non seulement très loin de ce que produit un alias authentique, mais se situe dans la queue de la distribution des auteurs absents.

| Traits | Distance      | Séparation de Ziak | Repère H <sub>1</sub><br>(auteur présent) | Repère H <sub>0</sub><br>(auteur absent) | Hypothèse favorisée |
|--------|---------------|--------------------|-------------------------------------------|------------------------------------------|---------------------|
| char   | burrows delta | -2,13              | -3,01                                     | -2,33                                    | H <sub>0</sub>      |
| char   | cosine delta  | -2,52              | -4,59                                     | -3,05                                    | H <sub>0</sub>      |
| mfw    | burrows delta | -2,22              | -3,27                                     | -2,40                                    | H <sub>0</sub>      |
| mfw    | cosine delta  | -2,83              | -4,83                                     | -3,26                                    | H <sub>0</sub>      |

Autrement dit, ce n'est pas seulement que la méthode ne trouve pas : c'est qu'elle trouve activement l'absence de correspondance.




Figure 3. Ziak confronté aux deux hypothèses, pour les quatre combinaisons. La distribution verte correspond aux cas où l'auteur est réellement dans le corpus, la grise aux cas où il en est absent ; le trait rouge marque la position de Ziak.


5.4 Robustesse

Trois objections méritent une réponse chiffrée. **La méthode est-elle moins puissante sur les artistes récents ?** C'est l'inverse : la puissance est maximale sur la génération de Ziak (97,7 % au premier rang pour 2021-2024). **Le seuil de 12 000 mots exclut-il le bon candidat ?** Le score de séparation reste compris entre -2,43 et -2,58 lorsqu'on fait varier ce seuil de 5 000 à 25 000 mots, faisant varier le pool de 472 à 268 artistes. **Les candidats récurrents résistent-ils à un test par paire ?**

Le test des imposteurs (Koppel & Winter, 2014) ne demande plus « qui est le plus proche ? » mais « ce candidat précis l'emporte-t-il sur un fond d'imposteurs tirés au hasard ? ». Il appelle une lecture en deux temps. D'un côté, les meilleurs candidats — Kerchak (0,82), Beendo Z (0,72), Rimkus (0,70) — battent largement le hasard (0,04) :

il existe une parenté stylistique réelle. De l'autre, un alias authentique obtient dans ce test un score médian de 1,00, et neuf vrais jumeaux sur dix dépassent 0,97. Le meilleur candidat de Ziak reste sous le niveau de 97,5 % des jumeaux authentiques.

Cette distinction — ressembler à un courant *versus* être la même personne — est précisément ce qu'un classement de distances non étalonné ne permet jamais de trancher.



**Figure 4.** (a) aucun candidat n'est stable d'une méthode à l'autre ; (b) même le meilleur candidat reste loin du niveau qu'atteint un véritable alias.

## 6. Validation sur des liens d'auteur réels

Tout ce qui précède repose sur une validation par jumeaux fabriqués : on coupe l'œuvre d'un artiste en deux et l'on cherche une moitié depuis l'autre. C'est une tâche *facile* — les deux moitiés partagent la même époque, les mêmes thèmes, le même producteur. La puissance qu'on y mesure est donc une borne optimiste, et c'est l'objection la plus sérieuse qu'on puisse opposer au verdict. Cette section y répond avec des cas où la vérité est connue indépendamment du corpus.

### 6.1 Recouvrements entre un artiste et son groupe

Le test d'alias idéal serait un artiste présent sous deux noms distincts. Il est irréalisable ici : **Genius fusionne lui-même les changements de nom**. Les titres de la période *Joke* sont classés sous *Ateyaba*, il n'existe aucune page « Joke », et LRFAF hérite de cette fusion. Vérification faite, les pages « Peter Punk » et « Malsain » trouvées sur Genius sont des homonymes — un groupe italien et un groupe de metal — et non Disiz ni Sinik.


Restent quatorze paires **solo / groupe** où l'artiste a réellement écrit une partie des textes du groupe. Le test est plus sévère qu'un alias : dans un trio, l'auteur ne signe qu'un tiers du texte, le reste étant écrit par d'autres. La requête est ramenée à la taille du corpus de Ziak, sans quoi Booba (114 983 mots) et Gringe (18 092) ne seraient comparables ni entre eux ni au cas étudié.

**Tableau 4.** Rang du groupe, interrogé depuis les textes solo de l'un de ses membres. L'effet de dilution est net : un duo se retrouve aisément, un groupe de huit se perd dans le classement.

| Artiste → groupe               | Rappeurs | Rang médian (sur 392) |
|--------------------------------|----------|-----------------------|
| Gringe → Casseurs Flowters     | 2        | 1                     |
| Rockin' Squat → Assassin (FRA) | 2        | 1                     |
| Akhenaton → IAM                | 3        | 2                     |
| Nekfeu → S-Crew                | 3        | 4                     |
| Alpha Wann → 1995              | 6        | 9                     |
| Kery James → Ideal J           | 2        | 9                     |
| Booba → Lunatic                | 2        | 13                    |
| Deen Burbigo → L'Entourage     | 5        | 13                    |
| Nekfeu → 1995                  | 6        | 23                    |
| Kool Shen → Suprême NTM        | 2        | 27                    |
| Tunisiano → Sniper             | 3        | 34                    |
| Black M → Sexion d'Assaut      | 8        | 49                    |
| Jazzy Bazz → L'Entourage       | 5        | 63                    |
| Lefa → Sexion d'Assaut         | 8        | 159                   |

Le lien est retrouvé dans le top 20 pour 57 % des paires — et 80 % des duos, cas le plus proche d'un alias. **La puissance réelle est donc inférieure aux 90 % mesurés sur jumeaux simulés** : il faut compter avec une chance sur cinq à une sur trois de manquer un lien, selon le degré de dilution.

#### Validation sur des recouvrements d'auteur réels, non simulés



**Figure 5.** Validation sur quatorze recouvrements d'auteur réels. (a) rang du groupe vu depuis le solo ; (b) plus l'auteur est dilué dans un collectif, moins il est détectable ; (c) le meilleur candidat de Ziak se détache moins que dans la quasi-totalité des cas à lien réel.


## 6.2 Un changement d'identité efface-t-il la signature ?

Reste l'objection de fond : un artiste qui se réinvente sous un autre nom change peut-être aussi de manière d'écrire. La fusion opérée par Genius permet justement de le tester, en découpant ces artistes **de part et d'autre de leur changement d'identité**. On interroge la période antérieure et l'on cherche la période postérieure, placée dans le pool sous une autre étiquette. Trois cas sont documentés dans le corpus, et le premier est le plus net : Ateyaba a publiquement déclaré vouloir « tuer Joke ».

**Tableau 5.** Période postérieure au changement de nom, recherchée depuis la période antérieure. La dernière ligne donne le repère : des artistes découpés au même endroit de leur carrière, mais qui n'ont jamais changé de nom.

| Changement d'identité              | Rang médian | Séparation | Trouvé au rang 1 |
|------------------------------------|-------------|------------|------------------|
| Joke → Ateyaba                     | 1           | -4,98      | 100 %            |
| Maître Gims → Gims                 | 5           | -2,91      | 10 %             |
| Disiz la Peste → Disiz             | 8           | -2,22      | 20 %             |
| Contrôles sans changement (n = 45) | 2           | -3,21      | 47 %             |

Le résultat est net, et il lève l'objection plutôt qu'il ne la confirme. **Joke → Ateyaba est retrouvé au premier rang sur 393 candidats, dans la totalité des tirages**, avec une séparation de -4,98 — alors même que le changement d'identité était revendiqué. Sur les trois cas, le rang médian passe de 2 (artistes sans changement) à 5, et la séparation reste inchangée (-3,21 contre -3,37). Changer de nom, de registre et d'époque ne suffit pas à effacer la signature.



**Figure 6.** Ce que coûte un changement d'identité. (a) les trois cas documentés ; (b) leur rang comparé à celui d'artistes n'ayant jamais changé de nom ; (c) séparation du meilleur candidat, seule grandeur comparable au cas Ziak.

Ces deux tests tirent dans des directions opposées, et il faut les lire ensemble. La puissance est *plus faible* qu'annoncée dès lors que l'auteur recherché ne signe qu'une partie des textes. Mais elle ne s'effondre *pas* lorsqu'il change d'identité, ce qui était la crainte principale. Or c'est bien cette seconde situation qui correspond à l'hypothèse testée sur Ziak. Sur la seule grandeur comparable — la séparation du meilleur candidat du classement — son favori se détache moins bien que dans 96 % de ces tests à lien réel.

## 7. Le cas Mikeysem

La conclusion précédente souffrait d'un angle mort : le nom le plus fréquemment avancé par les auditeurs, **Mikeysem**, ne figure pas dans LRFAF. Ce n'est pas un oubli du corpus mais une conséquence de son critère d'inclusion, qui part des catégories Wikipédia : Mikeysem n'a ni article Wikipédia ni entrée Wikidata. L'hypothèse la plus discutée était donc précisément celle que l'étude ne pouvait pas tester.


Ses titres ont été collectés sur Genius et passés dans le pipeline LRFAF reconstitué. **La couverture est partielle et c'est la principale faiblesse de cette section** : sa discographie compte 21 titres mais 7 seulement disposent d'une page Genius soit 3 745 mots — trois fois moins que la taille de référence employée jusqu'ici. Les autres n'ont aucune transcription disponible, dont l'intégralité du projet *Prochains Héritiers* (10 titres, 2022). Aller chercher ces paroles ailleurs romprait la compatibilité méthodologique avec LRFAF, dont toutes les transcriptions proviennent de Genius et de ses conventions.

Cette petitesse impose de recalibrer avant d'interpréter. À 3 745 mots de candidat, la méthode place le vrai auteur au premier rang dans 63 % des cas et dans le top 20 dans 95 % : la puissance baisse, mais un alias authentique resterait très majoritairement détectable.

**Tableau 6.** Rangs médians vus depuis Ziak, à taille strictement égale. Six artistes que personne ne soupçonne sont plus proches de Ziak que Mikeysem.

| Artiste  | Rang parmi 493 candidats |
|----------|--------------------------|
| Kerchak  | 4                        |
| Beendo Z | 8                        |
| ISK      | 10                       |
| Werenoï  | 12                       |
| Zkr      | 18                       |
| Rimkus   | 25                       |
| Mikeysem | 64                       |

Aucune des quatre combinaisons ne place Mikeysem dans le top 20 : son rang médian est de 58 sur 493. Son score de séparation (−1,22) est même plus faible que celui d'un auteur typiquement absent du corpus : il n'est pas un candidat ordinaire ayant manqué la première place, mais un artiste particulièrement éloigné. Au test des imposteurs, il obtient 0,07, à peine au-dessus du hasard (0,04), là où un alias authentique atteint 0,83 en médiane ; seuls 5 % des vrais jumeaux font moins bien.



**Figure 7.** Test de l'hypothèse Mikeysem. (a) puissance de la méthode à cette taille de corpus ; (b) rangs comparés ; (c) le score obtenu reste très en deçà de celui d'un véritable alias.

Une réserve doit accompagner ce résultat. Un contrôle d'auto-cohérence — une moitié du corpus de Mikeysem cherchant l'autre, avec environ 1 870 mots de chaque côté — échoue complètement. Ce test est plus exigeant que le test principal, qui dispose des 23 886 mots de Ziak comme requête, et ne remet donc pas en cause le classement ; mais il rappelle, avec la couverture partielle signalée plus haut, que la conclusion de cette section vaut comme faisceau convergent et non comme démonstration.

## 8. L'hypothèse web7 : un co-auteur crédité

Une autre version de la rumeur, rapportée par la presse musicale (Génération(s)), ne fait pas de Ziak un seul artiste mais en répartit les rôles : **web7**, anciennement 7 Jaws, écrivait les textes ; Mikeysem les interpréterait sous le masque ; le producteur Seezy serait « Hellboy ». Aucune preuve n'est citée, et web7 a refusé d'en parler sans démentir. Cette version rendrait d'ailleurs compte du résultat de la section 7 : si Mikeysem interprète sans écrire, ses propres textes n'ont aucune raison de ressembler à ceux de Ziak.

C'est une hypothèse de *ghostwriting*, qui ne se teste pas tout à fait comme un alias. Un auteur qui écrit pour la voix d'un autre adapte son registre, ce qui dilue sa signature. Surtout, deux composantes du texte transcrit n'appartiennent pas à l'auteur : les **ad-libs** de l'interprète (« uh », « huh », « gang »), que Genius note surtout entre parenthèses — c'est le cas de 87 % des « uh » de Ziak —, et les **couplets d'invités**, écrits par d'autres. Les deux ont été retirés.

### 8.1 Données et nettoyage

web7 ne figure pas dans LRFAF. Sa page Genius, qui répertorie « 7 Jaws » parmi ses noms, compte 80 titres satisfaisant aux critères du corpus, soit 40 225 mots — davantage que les 47 titres recensés sur Deezer, Genius conservant ses premiers EP et ses freestyles. Contrairement au cas Mikeysem, la matière ne manque pas.

Les couplets d'invités ont été retirés à partir des balises de section de Genius, qui nomment l'interprète de chaque passage. La règle retenue est stricte : une section n'est conservée que si elle revient au seul artiste principal, une section partagée étant écartée faute de pouvoir savoir qui en a écrit quoi. Cela retire 6,2 % des mots de Ziak et 5,4 % de ceux de web7. Ce nettoyage n'est possible que sur des paroles collectées directement : LRFAF a supprimé ces balises avant publication, si bien que ses artistes conservent leurs featurings. Ils ne servent ici qu'à étalonner l'échelle des traits.

## 8.2 Au niveau de l'artiste : aucune proximité

**Tableau 7.** Rang de web7 parmi les candidats, interrogé depuis les textes de Ziak. Aucune variante ne le rapproche des premiers rangs, ni le retrait des ad-libs, ni celui des featurings, ni la restriction à sa production contemporaine.

| Variante                                  | Rang médian de web7 | Dans le top 20 |
|-------------------------------------------|---------------------|----------------|
| Textes complets                           | 129 / 393           | 0 %            |
| Sans ad-libs                              | 132 / 390           | 0 %            |
| web7 depuis 2019, sans ad-libs            | 118 / 390           | 0 %            |
| Sans featurings ni ad-libs                | 136 / 390           | 0 %            |
| <i>Test inverse : Ziak vu depuis web7</i> | 137 / 390           | 0 %            |

Quelle que soit la variante, web7 se classe au-delà du centième rang et n'entre jamais dans le top 20. Sa séparation (−0,49) est sans commune mesure avec celles des liens d'auteur réels de la section 6. Dans le même temps, les voisins habituels de Ziak — Kerchak, Beendo Z, Werenoi — restent dans les premiers rangs : la méthode fonctionne normalement, elle ne trouve simplement pas web7.

## 8.3 Ce que disent les crédits

L'examen de la collecte a pourtant fait apparaître un fait documentaire. **Genius crédite web7 comme co-auteur de 10 des 75 titres de Ziak**, toujours aux côtés de Ziak lui-même : deux en 2021 (*Akimbo*, *Parasite*), huit en 2025, aucun en 2020 ni entre 2022 et 2024. Les auteurs sont renseignés pour chacun des 75 titres : l'absence de web7 sur les autres est donc une information, non une lacune.

Les deux constats se concilient. Parmi les 43 titres de Ziak qu'interroge le test principal, **deux seulement** sont crédités à web7, soit moins de 5 %. Or la section 6 a montré que la détection s'effondre quand l'auteur recherché ne signe qu'une petite fraction des textes. Un test mené au niveau de l'artiste ne pouvait donc pas voir une contribution aussi minoritaire — encore fallait-il vérifier qu'elle laisse une trace lorsqu'on la cherche au bon endroit. Ces crédits, saisis par la communauté de Genius et généralement recopiés des crédits officiels, restent à confirmer par une source indépendante.

## 8.4 Une expérience naturelle : *Essonne History X*

L'année 2025 offre une situation presque expérimentale. Sur les 23 titres de Ziak parus cette année-là, 22 appartiennent au même album, *Essonne History X*, dont les 8 titres co-crédités à web7 ; 15 titres ne le sont pas. Même artiste, même année, même disque : si la contribution de web7 laisse une trace, les titres crédités doivent être plus proches de ses propres textes que ne l'est un ensemble quelconque de titres de la même période.


Le test compare la distance entre le profil agrégé des huit titres crédités et celui de web7 à la même distance calculée pour 5 000 ensembles de huit titres tirés au hasard parmi les 23. La taille du groupe restant identique, l'effet de taille est neutralisé. Deux contrôles établissent la puissance du test : on remplace les titres crédités par des textes de web7 lui-même, écartés de son profil de référence, puis par un mélange à parts égales de textes de web7 et de Ziak.

**Tableau 8.** Expérience naturelle sur les titres de Ziak parus en 2025. La p-valeur est la part des tirages aléatoires de huit titres plus proches de web7 que les huit titres qui lui sont crédités.

|                                          | Sans featurings<br>ni ad-libs | Sans featurings<br>seulement |
|------------------------------------------|-------------------------------|------------------------------|
| Distance à web7 — 8 titres crédités      | 0,885                         | 0,881                        |
| Distance à web7 — 15 titres non crédités | 0,938                         | 0,942                        |
| Médiane de 5 000 tirages de 8 titres     | 0,934                         | 0,936                        |
| <b>p-valeur</b>                          | <b>0,038</b>                  | <b>0,026</b>                 |
| Contrôle 100 % web7 — détecté            | 100 %                         | 100 %                        |
| Contrôle 50 % web7 — détecté             | 83 %                          | 78 %                         |

**Les titres co-écrits avec web7 sont significativement plus proches de son écriture que les autres titres de la période** ( $p = 0,038$  sans featurings ni ad-libs,  $0,026$  sans featurings seulement). Les contrôles montrent que le test pouvait le voir : un texte entièrement de web7 est détecté dans 100 % des tirages, un mélange à parts égales dans 83 %.

Trois précisions bornent la portée de ce résultat. Une p-valeur de cet ordre est modeste : elle repose sur une seule expérience de huit titres, parmi plusieurs tests apparentés. Le biais de taille joue *contre* elle : les titres crédités sont plus courts (317 mots en moyenne contre 416), donc plus bruités, et en principe plus éloignés de tout profil. Enfin, le signal observé est plus faible que celui d'une co-écriture à parts égales dans le style propre de web7, ce qui cadre avec une contribution partielle, ou écrite dans la voix de Ziak. Toutes années confondues, sans contrôle de l'époque, la tendance persiste sans atteindre le seuil ( $p = 0,064$ ).



**Figure 8.** L'hypothèse web7. (a) au niveau de l'artiste, web7 se classe loin derrière les voisins de Ziak ; (b) sur l'album *Essonne History X*, les huit titres co-crédités sont plus proches de web7 que des tirages aléatoires de huit titres ; (c) contrôles de puissance : le test détecte un texte entièrement ou à moitié écrit par web7.

Crédits et stylométrie convergent donc vers une lecture sobre. web7 est un co-auteur réel d'une partie des titres de Ziak, et sa contribution laisse une trace mesurable lorsqu'on la cherche là où elle est créditée. Rien, en revanche, ne soutient la version forte de la rumeur : sur 2020-2024, ni les crédits ni les textes n'indiquent que web7 écrive l'essentiel des textes de Ziak, et rien ne concerne le masque ni l'identité de l'interprète. La leçon de méthode est nette : une attribution menée au niveau de l'artiste ne voit pas un co-auteur minoritaire, qu'un contraste ciblé à l'intérieur de l'œuvre permet de détecter.

## 9. Portrait stylométrique de Ziak


À défaut d'identifier Ziak, on peut le caractériser. Deux mesures doivent être distinguées : la distance médiane à l'ensemble du corpus, qui dit s'il est atypique ; et la distance à son plus proche voisin, qui dit s'il a un parent.

Ziak n'a rien d'un excentrique : il se situe au rang 176 sur 393, au milieu exact du genre, très loin des vrais atypiques du corpus que sont Manau, Grand Corps Malade ou Rocé. Et pourtant **il n'a pas de proche parent** : 68 % des artistes ont un voisin plus proche que le sien. C'est exactement la signature attendue d'un auteur qui écrit dans les codes d'un courant sans qu'aucun artiste du corpus ne soit sa seconde identité.

Ses marqueurs les plus robustes sont des **onomatopées** : « uh » (×149), « huh » (×87), « pow » (×64), les ad-libs qui ponctuent ses morceaux, suivis d'un argot situé (« zipette », « sheitan »).

Une mise en garde s'impose toutefois sur ces marqueurs. Le trait le plus spectaculaire de son corpus, à première vue, est un sous-emploi massif de « je » — cinq fois moins que la moyenne. C'est un artefact : il emploie « j' » 1,2 fois plus, et une fois les deux formes additionnées l'écart disparaît complètement (×0,99). La moitié des paires testées relève du même phénomène. Ce que l'on mesurait n'était pas une habitude d'écriture mais une convention de transcription : les paroles de Genius sont saisies par des contributeurs bénévoles, et « j'suis » ou « je suis » notent la même diction.

Enfin, l'écart entre ses deux périodes de production (2020-2021 et 2022-2024) dépasse à peine ce que produit une coupe aléatoire de son œuvre ( $z = +1,71$ , sous le seuil usuel de 2) : son style évolue un peu, sans rupture.



**Figure 9.** Portrait stylométrique. (a) marqueurs lexicaux ; (b) Ziak n'a pas de proche parent ; (c) l'élimination, un faux marqueur qui vient du transcripateur et non de l'auteur.

## 10. Limites

**Le corpus n'est pas le rap français.** LRFAF couvre 596 artistes, et l'analyse n'en retient que 393 — ceux disposant d'au moins 12 000 mots. Un artiste peu documenté, ou absent de Genius, ne pouvait pas être détecté. La section 7 lève ce point pour le seul candidat qui comptait vraiment, mais il en reste d'autres, hors corpus et non testés.

**Les featurings ne sont séparés que pour les données collectées.** Les paroles de LRFAF ne comportent aucune balise de section : le couplet d'un invité y est attribué à l'artiste principal. Ce bruit affecte Ziak comme les candidats, et tend à rapprocher artificiellement les artistes qui collaborent — donc à faciliter une détection, non à l'empêcher. Pour les textes collectés directement sur Genius (section 8), les couplets d'invités ont été retirés.

**Les transcriptions sont médiées.** Comme le montre le cas de l'élimination, une partie du signal apparent vient des contributeurs de Genius plutôt que des artistes. Les 4-grammes de caractères y sont moins sensibles que les mots, sans y être immunisés.

**Le corpus de Mikeyssem est mince et partiel** : 3 745 mots, couvrant 7 de ses 21 titres. C'est la conclusion la moins solidement étayée de ce travail.

**La puissance dépend de ce que l'on cherche.** La section 6 l'a mesurée sur des liens réels plutôt que simulés : elle chute nettement quand l'auteur recherché ne signe qu'une partie des textes (un membre parmi huit se perd au-delà du centième rang), mais résiste à un changement d'identité revendiqué. La conclusion « Ziak n'est personne du corpus » vaut donc pour un alias qui écrirait seul ; elle serait plus fragile s'il s'agissait d'une participation diluée dans un collectif.

**Un auteur non crédité reste difficile à voir.** La section 8 le montre : un co-auteur présent sur une minorité de titres échappe à l'analyse menée au niveau de l'artiste, et ne se détecte que par un contraste ciblé — à condition de savoir où chercher, c'est-à-dire de disposer des crédits. Un nègre littéraire non crédité, écrivant dans la voix d'un autre, pourrait n'être détecté par aucune des deux approches.

## 11. Conclusion

L'hypothèse du pseudonyme était testable, et le test est concluant : aucun des 392 autres artistes éligibles du corpus LRFAF ne présente la signature stylométrique de Ziak, alors qu'un protocole validé sur 177 cas connus retrouve le bon auteur neuf fois sur dix — et dans 97,7 % des cas pour sa génération. Les quatre analyses convergent vers l'hypothèse d'un auteur absent du corpus, et le test par paire montre que même le meilleur candidat reste en deçà de 97,5 % des alias authentiques. Le nom que la rumeur avance le plus souvent, testé à son tour, se classe 58<sup>e</sup> sur 493, derrière six artistes que personne ne soupçonne.

Une dernière version de la rumeur, selon laquelle web7 (ex-7 Jaws) écrivait les textes de Ziak, appelait une réponse plus nuancée. web7 est crédité co-auteur de 10 des 75 titres de Ziak, et, sur l'album *Essonne History X*, les titres qu'il co-signe sont stylométriquement plus proches de son écriture que les autres ( $p = 0,04$ ). Rien n'indique en revanche qu'il écrive l'essentiel de l'œuvre : sur la période que couvre LRFAF, il n'est crédité que sur deux titres.

Cette puissance a été éprouvée sur des liens d'auteur **réels** et non plus simulés (section 6) : la méthode retrouve Joke → Ateyaba au premier rang sur 393 candidats, malgré un changement d'identité revendiqué. Elle perd en revanche sa capacité de détection lorsque l'auteur recherché ne signe qu'une fraction des textes — un membre parmi huit se perd au-delà du centième rang.

Ce que l'on observe à la place a sa propre valeur descriptive : Ziak écrit au centre de son genre, sans excentricité mesurable, mais sans proche parent non plus. Sa parenté avec Kerchak ou Beendo Z est celle d'une génération et d'un sous-genre partagés, pas d'une main commune.

La contribution la plus transposable de ce travail est cependant méthodologique. Une même question, posée au même corpus, reçoit deux réponses opposées selon le protocole : l'approche intuitive désigne un artiste avec assurance et se trompe trois fois sur quatre ; l'approche étalonnée ne désigne personne, et sait dire pourquoi. Entre les deux, il n'y a pas un algorithme plus sophistiqué, mais trois exigences ordinaires — contrôler une variable de confusion, valider sur des cas connus, calibrer contre une hypothèse nulle.

### Note éthique

Cette étude porte sur une personne réelle ayant fait le choix de l'anonymat. Deux précautions ont guidé le travail. Elle s'appuie exclusivement sur des données publiques de recherche et sur des textes publiés, sans recours à aucune information personnelle. Surtout, la stylométrie n'établit pas d'identité civile : une correspondance forte aurait constitué un indice de parenté textuelle, jamais une preuve — et elle aurait appelé, à ce titre, une retenue plus grande encore dans sa publication que le résultat négatif obtenu ici. Le rapprochement avec Mikeysem, en particulier, est une spéculation d'auditeurs que l'intéressé a démentie et qu'aucune source vérifiable n'étaye. La section 8 s'appuie en outre sur des crédits d'auteur publics : ils documentent une co-écriture, non une identité, et ne disent rien de la personne qui porte le masque. Le résultat de cette enquête est, à sa manière, une confirmation de la robustesse de cet anonymat face aux méthodes quantitatives.

### Reproductibilité

L'ensemble des analyses est reproductible depuis le dépôt du projet. Les scripts s'exécutent dans l'ordre : construction du cache de compteurs, diagnostic du biais de taille, validation du protocole, application à Ziak, robustesse, portrait, collecte de Mikeysem et test de l'hypothèse, validation sur liens réels, collecte de web7 et de Ziak sur Genius, tests de l'hypothèse web7, figures. Le corpus LRFAF n'étant pas versionné (114 Mo), il est retéléchargé depuis Hugging Face. Le pipeline LRFAF reconstitué et son rapport de reproductibilité — qui documente colonne par colonne ce qui est reproduit exactement, approximé ou impossible à retrouver — accompagnent le dépôt.

## Références

- Burrows, J. (2002). Delta : a measure of stylistic difference and a guide to likely authorship. *Literary and Linguistic Computing*, 17(3), 267-287.
- de Courson, B. (2024). *LRFAF : une exploration numérique du rap français depuis les années 1990*. Jeu de données : [huggingface.co/datasets/regicid/LRFAF](https://huggingface.co/datasets/regicid/LRFAF)
- Evert, S., Proisl, T., Jannidis, F. *et al.* (2017). Understanding and explaining Delta measures for authorship attribution. *Digital Scholarship in the Humanities*, 32(suppl. 2), ii4-ii16.

Générations. « Ziak : 7 Jaws/Web 7 se cache-t-il sous le masque ? Sa réponse cash ! » *generations.fr*.

Koppel, M. & Winter, Y. (2014). Determining if two documents are written by the same author. *Journal of the Association for Information Science and Technology*, 65(1), 178-187.

Monroe, B., Colaresi, M. & Quinn, K. (2008). Fightin' words : lexical feature selection and evaluation for identifying the content of political conflict. *Political Analysis*, 16(4), 372-403.

Piolat, A., Booth, R. J., Chung, C. K., Davids, M. & Pennebaker, J. W. (2011). La version française du dictionnaire pour le LIWC. *Psychologie Française*, 56(3), 145-159.

Smith, P. & Aldridge, W. (2011). Improving authorship attribution : optimizing Burrows' Delta method. *Journal of Quantitative Linguistics*, 18(1), 63-88.