


Chaîne de traitement des données

Enquête stylométrique sur l'identité de Ziak — corpus LRFAF

Tassilo Westphalen · CPES Sciences des données, Arts et Cultures — PSL / Louis-le-Grand



CE QUE LA CHAÎNE ÉTABLIT

L'approche intuitive identifie le bon auteur dans 25 % des cas ; le protocole contrôlé, dans 90 %.

Les trois corpus traversent le même moteur et les mêmes analyses :
si le verdict ne change pas, les featurings n'ont rien faussé.

Le détail, étape par étape

1. Récupérer le corpus

Le corpus LRFAF est téléchargé depuis Hugging Face : 37 307 chansons de rap français, 596 artistes, avec pour chacune les paroles, l'année et l'URL Genius d'origine. Ces paroles ont déjà été nettoyées par le constructeur du corpus — et privées de leurs balises de section, ce qui posera problème à l'étape 5.

2. Collecter les artistes absents

Mikeysem et web7 ne figurent pas dans le corpus : sans page Wikipédia, ils tombent hors de son critère d'inclusion. Ils sont collectés sur Genius, ainsi que Ziak, pour disposer de ses paroles avec leurs balises. Chaque identité est vérifiée à la main, un homonyme ruinant le test.

3. Préparer le texte

Nettoyage (les accents et l'apostrophe sont conservés : les premiers portent du signal en français, la seconde porte l'élision), puis découpe en mots et en suites de quatre caractères, puis filtrage — les textes de moins de 100 mots et les doublons entre artistes sont écartés. Les comptes sont mis en cache **par chanson** : un document d'artiste de n'importe quelle taille se recompose ensuite par simple addition, ce qui rend possibles les centaines de rééchantillonnages dont dépend la validation.

4. Analyser le corpus publié

Treize scripts, dans un ordre qui n'est pas décoratif. D'abord *valider* : établir que la méthode retrouve le bon auteur quand on connaît déjà la réponse. Ensuite *tester* les trois hypothèses. Enfin *décrire*. Un résultat négatif ne vaut rien tant qu'on n'a pas mesuré ce que la méthode sait trouver.

5. Récupérer les balises de section

Le corpus publié a perdu ses balises : impossible d'y distinguer le couplet de l'artiste de celui de son invité. Or laisser le couplet d'un invité dans le corpus de l'artiste principal rapproche mécaniquement les deux — et l'hypothèse testée porte justement sur une proximité. L'information n'est pas perdue : le corpus garde l'URL de chaque morceau, et la page Genius porte encore ses balises. 34 666 pages sont re-téléchargées, en six heures environ.

6. Reconstruire deux corpus propres

La difficulté est de distinguer un membre de groupe d'un invité : la règle naïve viderait les groupes de leur contenu, les balises y nommant les membres, dont les couplets *sont* le texte du groupe. Un intervenant récurrent est donc tenu pour interne. Deux corpus en sortent : l'un retire les strophes d'invités (12 % des mots), l'autre écarte en entier tout titre qui en comporte (8 280 titres).

7. Rejouer l'étude sur chaque corpus

Les mêmes scripts sont relancés sur chaque variante, avec un cache et un dossier de résultats séparés : les chiffres du corpus publié restent intacts. C'est le test décisif — **si le verdict est le même sur les trois, les featurings n'ont jamais faussé l'analyse**, et on le sait au lieu de le supposer.

8. Produire l'article

Les figures sont fabriquées depuis les CSV, et le texte de l'article relit tous les chiffres dans les résultats au moment de la génération : aucune valeur n'est écrite à la main, donc aucune ne peut se désynchroniser de l'analyse qu'elle cite. Deux moteurs partagent ce texte, l'un vers le PDF, l'autre vers le Word.

Reproduire

La chaîne s'exécute d'une commande. Chaque étape est idempotente : ce qui existe n'est pas refait, et une relance reprend où elle s'est arrêtée. Une exécution complète à partir de rien demande un peu plus de sept heures, dont six pour la seule étape 5 ; les suivantes tiennent en quarante minutes.

```
./pipeline.sh
./pipeline.sh --depuis variantes
./pipeline.sh balises --oui
```